

Relatório -Trabalho Prático 4

Redes Neurais na Previsão de Ataques Epilépticos

Realizado por:

2009109673 – Daniel Frutuoso

2009111924 – Igor Cruz

Grupo 4

Faculdade de Ciências e Tecnologias da UC

Departamento de Engenharia Informática

Coimbra, 06 de Dezembro de 2012

1 Introdução

Neste trabalho pretende-se testar várias arquitecturas e características de redes neuronais e saber qual a melhor configuração para a previsão de ataques epilépticos perante os dados reais, fornecidos pelo docente.

Na fase posterior pretende-se ainda escolher um subconjunto mais pequeno de sensores com as melhores características de forma a limitar a quantidade de sensores que o paciente teria de utilizar numa implementação real para utilização no dia-a-dia.

2 Separação de Dados

Para a realização deste trabalho os dados de input foram analisados e separados pelo script **tp4_132_caracteristicas.m** da seguinte forma:

- 1 - Contagem do número total de crises presentes no ficheiro;
- 2 – Eliminação uma parte do inter-ictal, ficando com apenas 100 pontos antecedentes a um pre-ictal de forma a que as classes fiquem equilibradas.
- 2 – Criação de matriz treino com 70% das crises
- 3 – Criação de matriz teste com 15% das crises
- 4 – Criação de matriz validação com 15% das crises

Note-se que devido ao elevado número de dados existentes para o período inter-ictal, decidimos atribuir apenas os 100 pontos antecedentes a cada período pré-ictal para cada crise. Para além disso, decidimos ainda ignorar a primeira crise, visto que a recolha de dados do nosso paciente começava num período pré-ictal e não inter-ictal.

Para a realização da segunda parte do trabalho foi criado um script que escolhe apenas as melhores 6 características. Mais à frente este processo é explicado.

3 Fase I – Utilização de 132 inputs

Numa primeira fase do trabalho utilizamos toda a informação presente no input, isto é, utilizamos os 132 sensores para construção de uma rede neuronal capaz de prever ataques epilépticos.

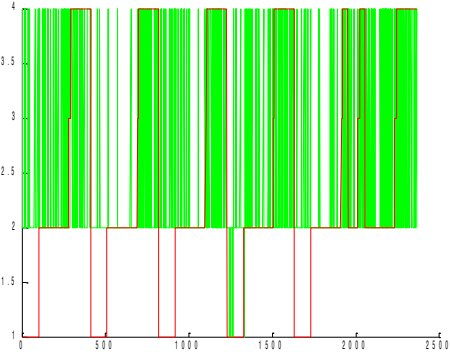
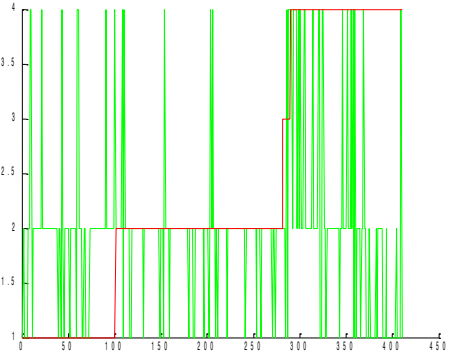
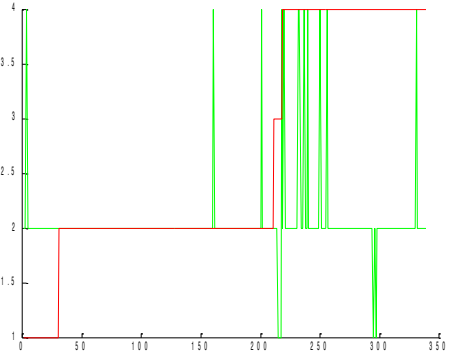
A utilização desta quantidade de inputs leva a um desempenho bastante lento por parte das redes neuronais havendo mesmo algumas que demora horas a treinar.

Os dados de input foram normalizados no intervalo $[-1 \ 1]$ de forma a atenuar o ruído.

Para avaliação do desempenho da nossa rede utilizámos várias métricas, de entre elas decidimos elaborar gráficos comparativos entre os outputs desejados (a vermelho) e o output da rede (a verde). Note-se que no eixo das abcissas, os valores de 1 a 4 representam os estados do paciente. Por exemplo, o estado 1 representa o período inter-ictal e estado 2 representa o pré-ictal. No eixo das ordenadas encontram-se representados os instantes temporais.


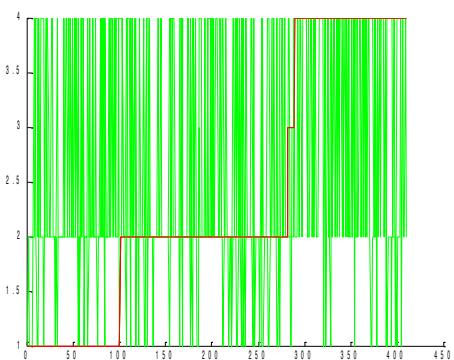
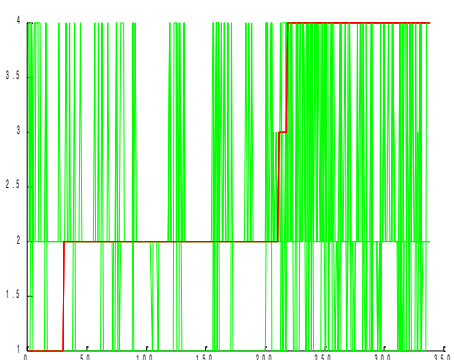
Rede FeedForward

1 Camada escondida com 5 neurónios, função de treino 'traingdx', função de performance 'mse', erro médio quadrático.

Treino	
	Precisão do Classificador : 0.5535 Sensibilidade : 0.7283 Especificidade : 0.8590
Teste	
	Precisão do Classificador : 0.4756 Sensibilidade : 0.6367 Especificidade : 0.8485
Validação	
	Precisão do Classificador : 0.5516 Sensibilidade : 0.9227 Especificidade : 0.9862
<p>Como podemos observar o desempenho ficou muito a quem das expectativas, errou muitos casos no ficheiro de teste e a rede ficou muito confusa com o ficheiro de treino. Ainda assim vamos tentar outra função de treino com apenas 5 neurónios.</p>	

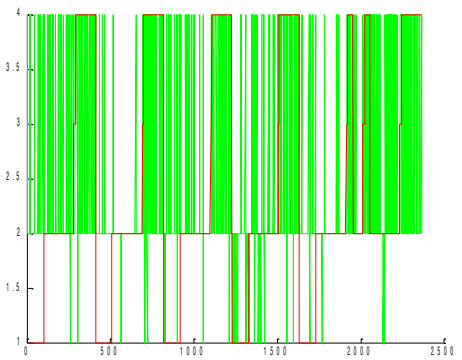
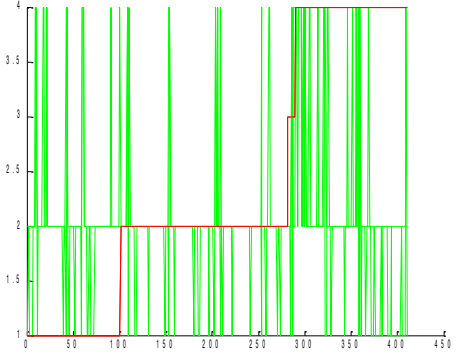
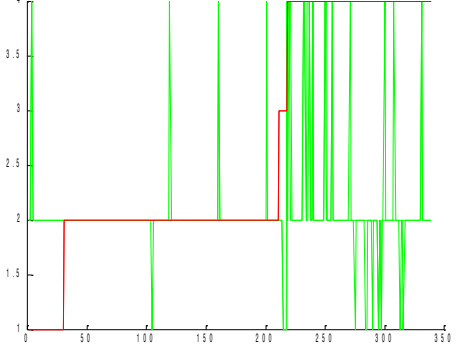
Rede FeedForward

1 Camada escondida com 5 neurónios , função de treino 'trainlm', função de performance 'mse', erro médio quadrático.

Treino	
	Precisão do Classificador : 0.7952 Sensibilidade : 0.4920 Especificidade : 0.5613
Teste	
	Precisão do Classificador : 0.5122 Sensibilidade : 0.4686 Especificidade : 0.5965
Validação	
	Precisão do Classificador : 0.2006 Sensibilidade : 0.0307 Especificidade : 0.0500
Com a função 'trainlm' o desempenho diminuiu drasticamente pelo que optámos por continuar a utilizar o 'trangux'.	

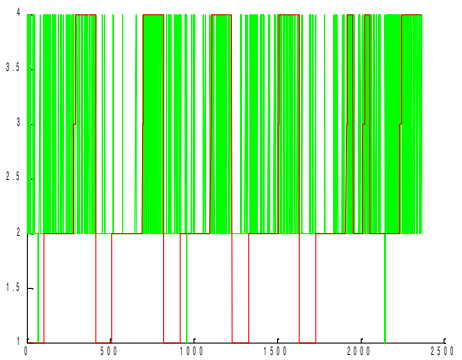
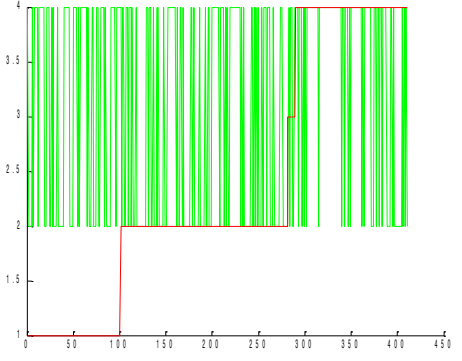
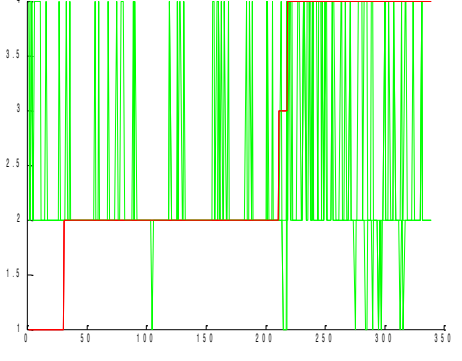
Rede FeedForward

1 Camada escondida com 10 neurónios , função de treino 'traingdx', função de performance 'mse', erro médio quadrático.

Treino	
	Precisão do Classificador : 0.5565 Sensibilidade : 0.7189 Especificidade : 0.8539
Teste	
	Precisão do Classificador : 0.4512 Sensibilidade : 0.8918 Especificidade : 0.9630
Validação	
	Precisão do Classificador : 0.5723 Sensibilidade : 0.8599 Especificidade : 0.8653
Como podemos observar o desempenho continua muito fraco sendo as melhorias quase nulas. Deste modo decidimos aumentar o número de camadas escondidas.	

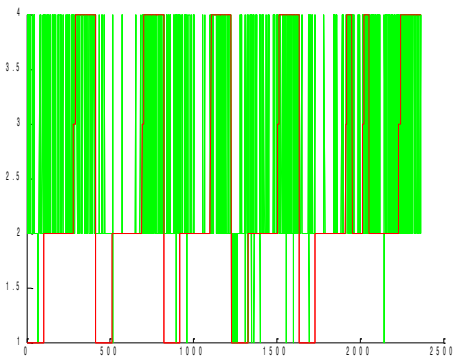
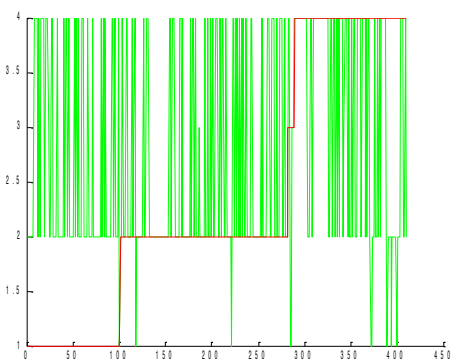
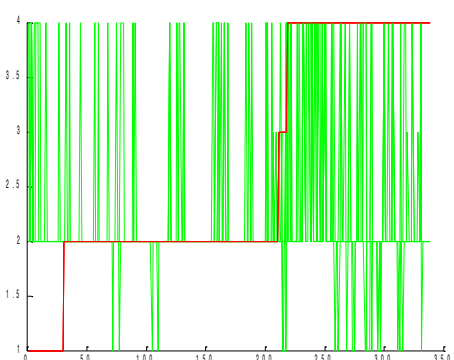
Rede FeedForward

2 Camada escondida com [10 5] neurónios , função de treino 'traingdx', função de performance 'mse', erro médio quadrático.

Treino	
	Precisão do Classificador : 0.5569 Sensibilidade : 0.7292 Especificidade : 0.8609
Teste	
	Precisão do Classificador : 0.4537 Sensibilidade : 0.3984 Especificidade : 0.4939
Validação	
	Precisão do Classificador : 0.5988 Sensibilidade : 0.7037 Especificidade : 0.7642
Apesar do aumento do número de camadas o desempenho foi ainda pior. Iremos então aumentar o número de neurónios em cada camada.	

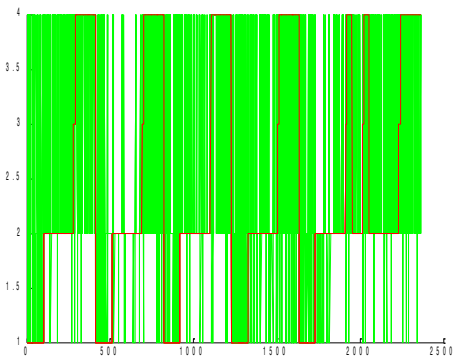
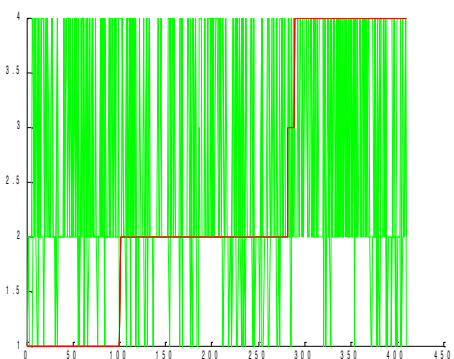
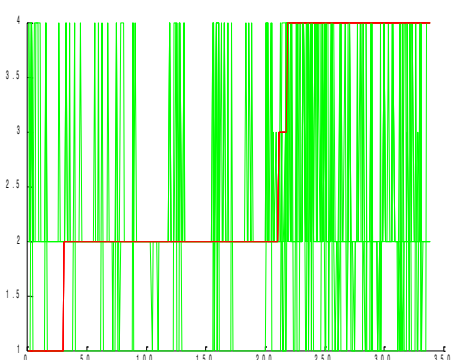
Rede FeedForward

2 Camada escondida com [20 10] neurónios , função de treino 'traingdx', função de performance 'mse', erro médio quadrático.

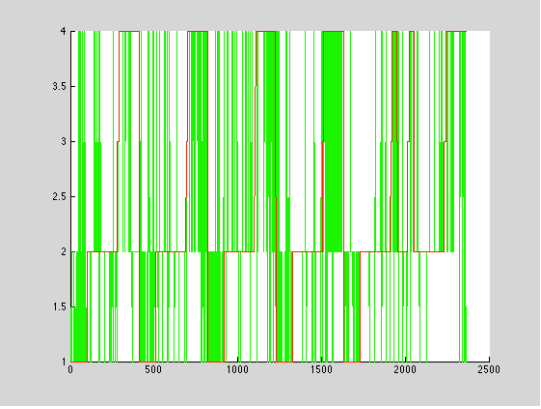
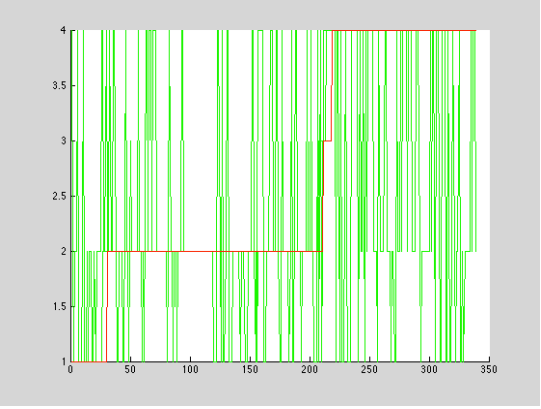
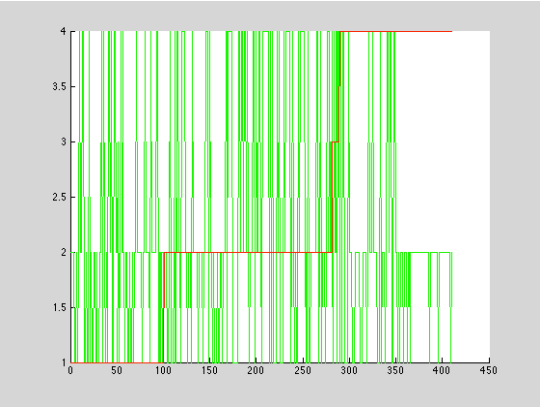
Treino	
	Precisão do Classificador : 0.5552 Sensibilidade : 0.7114 Especificidade : 0.8362
Teste	
	Precisão do Classificador : 0.4780 Sensibilidade : 0.5021 Especificidade : 0.6450
Validação	
	Precisão do Classificador : 0.5870 Sensibilidade : 0.7591 Especificidade : 0.8824
Apesar do aumento do número de neurónios na primeira camada o desempenho foi ainda pior. Iremos então testar outro tipo de rede.	

Rede Patternnet

2 Camada escondida com [15 15] neurónios , função de treino 'traingdx', função de performance 'mse', erro médio quadrático.

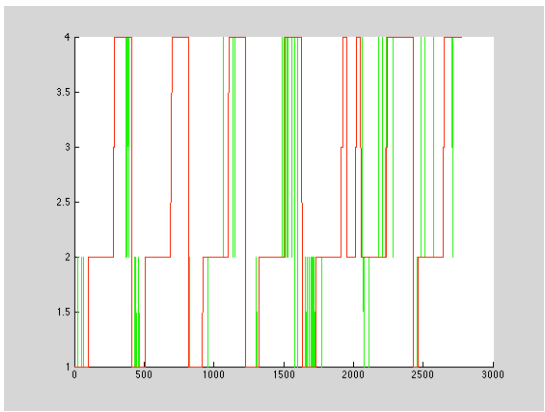
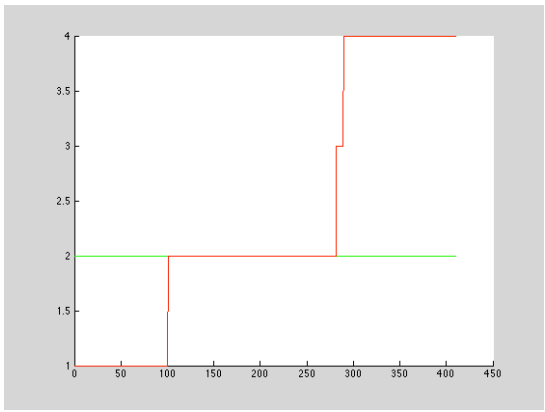
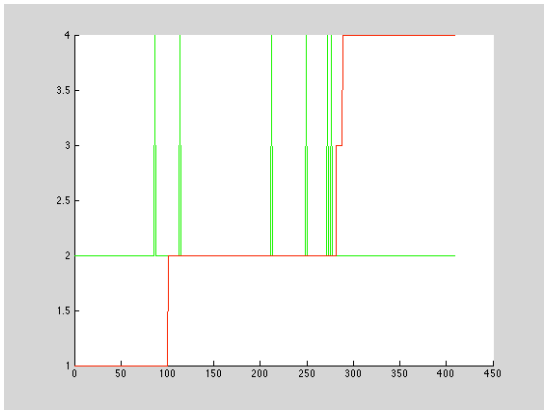
Treino	
	Precisão do Classificador : 0.5578 Sensibilidade : 0.7094 Especificidade : 0.8340
Teste	
	Precisão do Classificador : 0.4732 Sensibilidade : 0.6383 Especificidade : 0.7229
Validação	
	Precisão do Classificador : 0.5457 Sensibilidade : 0.9043 Especificidade : 0.7272
Verificámos que independentemente da rede utilizada, número de neurónios ou função de treino o desempenho fica à quem das expectativas pelo decidimos optar pelas redes com delay, visto o cérebro pode ser encarado como um sistema dinâmico.	

Rede Radial Basis

Treino	
	<p>Precisão do Classificador : 0.7562</p> <p>Sensibilidade : 0.6532</p> <p>Especificidade : 0.7569</p>
Validação	
	<p>Precisão do Classificador : 0.4688</p> <p>Sensibilidade : 0.4555</p> <p>Especificidade : 0.5665</p>
Teste	
	<p>Precisão do Classificador : 0.3664</p> <p>Sensibilidade : 0.6997</p> <p>Especificidade : 0.3656</p>

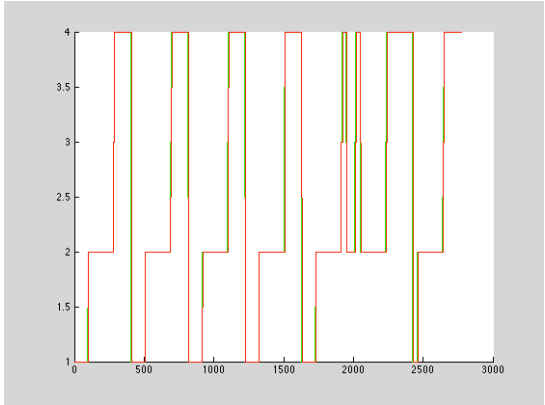
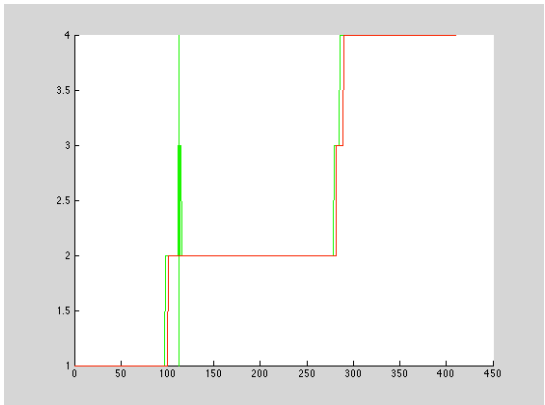
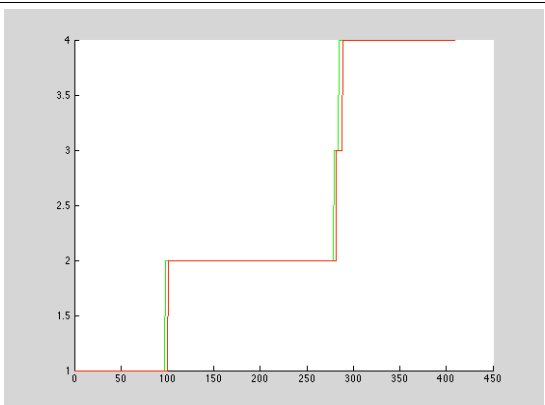
Rede Radial Basis

Erro = 0.02; Neurónios=1669

Treino	
	<p>Precisão do Classificador : 0.9830 Sensibilidade : 0.9887 Especificidade : 0.9792</p>
Validação	
	<p>Precisão do Classificador : 0.4415 Sensibilidade : 1 Especificidade : 0</p>
Teste	
	<p>Precisão do Classificador : 0.4303 Sensibilidade : 0.9724 Especificidade : 0.0044</p>
<p>Para nossa surpresa esta rede apresenta uma má especificidade mas apresenta uma boa sensibilidade. Isto indica que com esta rede não conseguimos identificar muito bem indivíduos sem doença, pelo menos para este caso. Quando tentámos novamente mas desta vez definindo o erro igual a zero, os resultados foram bastante piores.</p>	

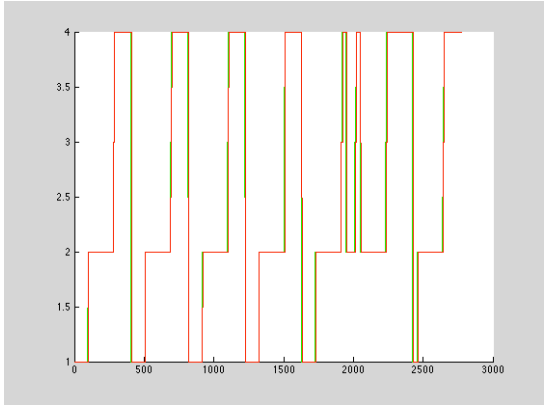
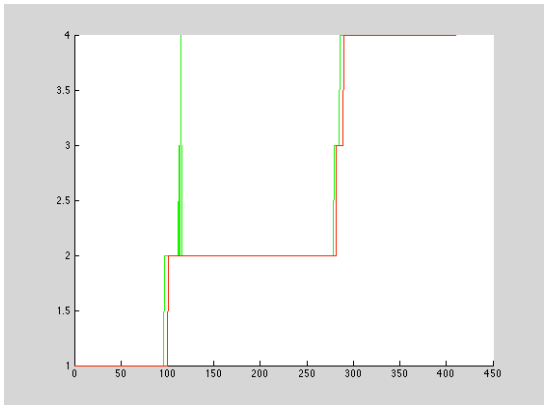
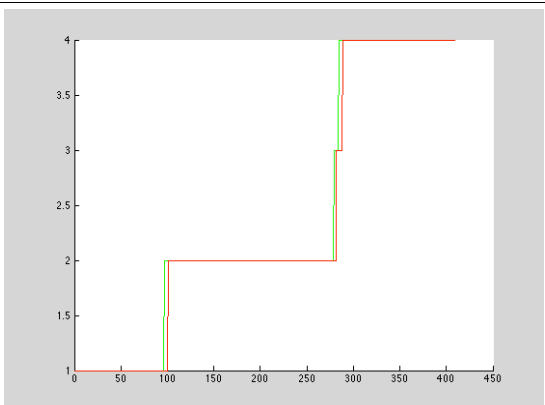
Rede Narxnet

1 camada com 10 neurónios; função de treino: traingdx; função de performance 'mse', erro médio quadrático.

Treino	
	Precisão do Classificador : 0.9628 Sensibilidade : 0.9812 Especificidade : 0.9806
Validação	
	Precisão do Classificador : 0.9654 Sensibilidade : 0.9613 Especificidade : 0.9866
Teste	
	Precisão do Classificador : 0.9752 Sensibilidade : 0.9834 Especificidade : 0.9865
Após visualização dos resultados podemos concluir que esta rede tem um excelente desempenho em relação às anteriores. Vamos então variar atributos para ver se conseguimos melhorar ainda mais.	

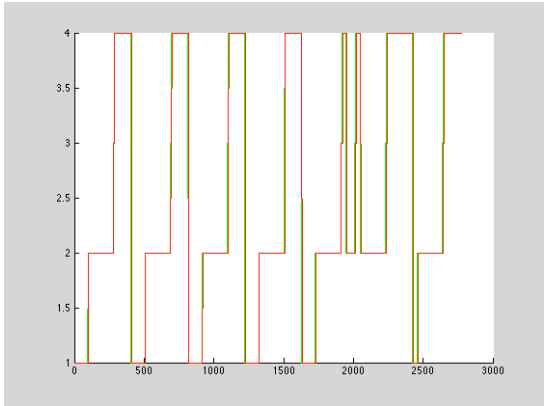
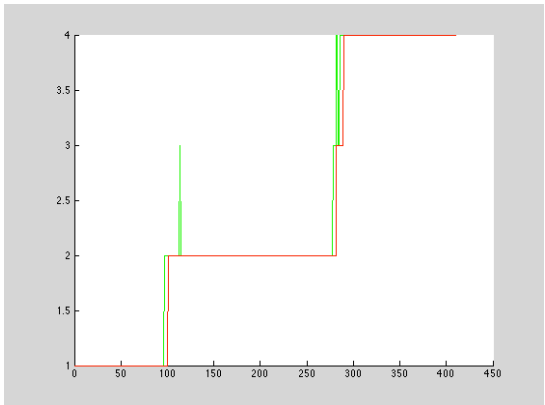
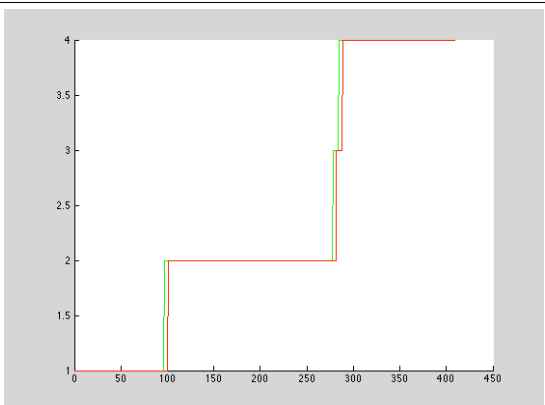
Rede Narxnet

1 camada com 20 neurónios; função de treino: traingdx; função de performance 'mse', erro médio quadrático.

Treino	
	Precisão do Classificador : 0.9610 Sensibilidade : 0.9812 Especificidade : 0.9778
Validação	
	Precisão do Classificador : 0.9679 Sensibilidade : 0.9724 Especificidade : 0.9821
Teste	
	Precisão do Classificador : 0.9728 Sensibilidade : 0.9834 Especificidade : 0.9821
Apesar de as alterações terem revelado algumas melhorias, nós não as consideramos significantes, pelo que optámos por testar a mesma rede mas com mais uma camada.	


Rede Narxnet

2 camada com 10 neurónios em cada; função de treino: traingdx; função de performance 'mse', erro médio quadrático.

Treino	
	Precisão do Classificador : 0.9555 Sensibilidade : 0.9751 Especificidade : 0.9778
Validação	
	Precisão do Classificador : 0.9630 Sensibilidade : 0.9724 Especificidade : 0.9821
Teste	
	Precisão do Classificador : 0.9703 Sensibilidade : 0.9779 Especificidade : 0.9821
Ao introduzir mais uma camada não se verificaram melhorias praticamente nenhuma. Na verdade foi maior o que se perdeu do que aquilo que ganhámos com esta arquitectura. Outras tentativas foram efectuadas, nomeadamente a alteração dos delays mas a primeira configuração foi a melhor.	

4 Fase II – Utilização de 6 inputs

Nesta fase foram apenas consideradas 6 características. O script `tp4_6_caracteristicas.m` é utilizado para escolher quais os melhores sensores a utilizar como input. Após análise dos valores de input chegamos à conclusão de que esses sensores seriam 5, 27, 49, 71, 93, 115.

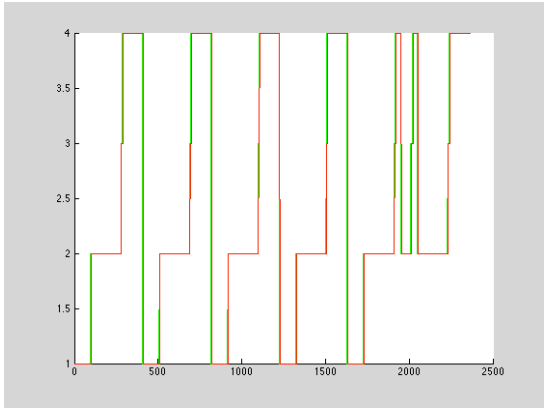
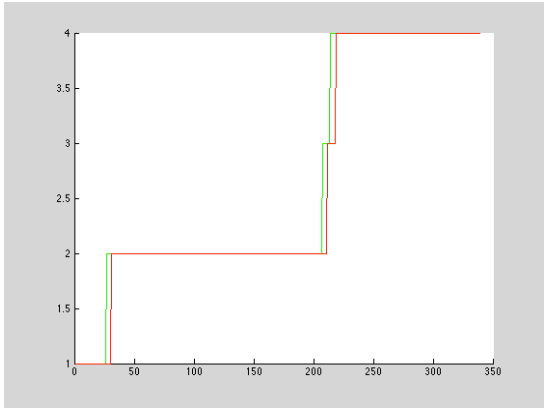
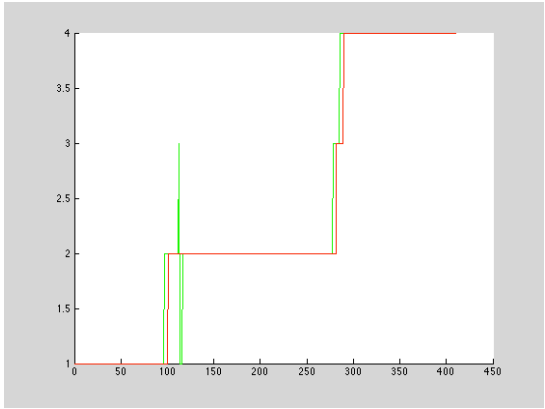


O gráfico representa a azul uma sobreposição dos valores obtidos pelos sensores durante os estados pré-ictais. Na intersecção das linhas vermelhas com as azuis podemos verificar os valores dos sensores escolhidos como ótimos, referidos acima.

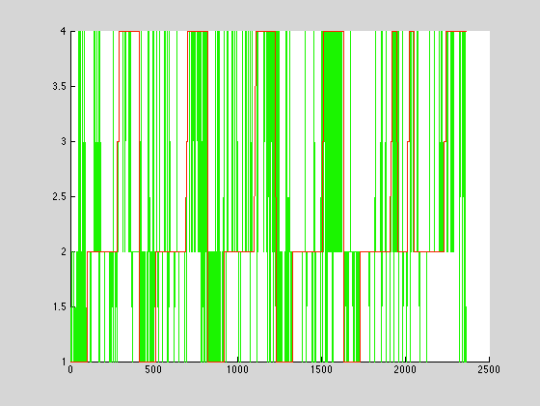
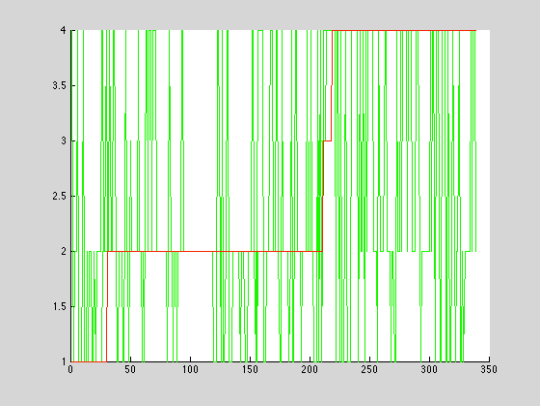
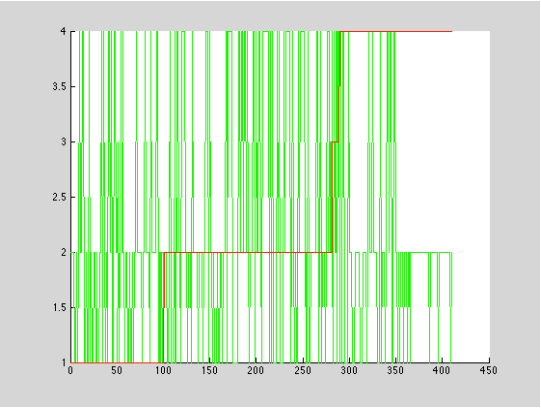
Nesta fase, não foram testadas as todas as redes feitas na fase 1, visto que o seu desempenho foi medíocre. Assim sendo foram apenas testadas as melhores configurações.

Rede Narxnet

Camada escondida com 10 neurónios , função de treino 'traigdx', função de performance 'mse', erro médio quadrático, inputDelays 1:5 feedbackDelays 1:5.

Treino	
	<p>Precisão do Classificador : 0.9563 Sensibilidade : 0.9756 Especificidade : 0.9769</p>
Teste	
	<p>Precisão do Classificador : 0.9580 Sensibilidade : 0.9503 Especificidade : 0,9821</p>
Validação	
	<p>Precisão do Classificador : 0.9611 Sensibilidade : 0.9779 Especificidade : 0.9739</p>
Como podemos observar esta foi uma das melhores redes neuronais testadas até ao momento.	

Rede Radial Basis

Treino	
	<p>Precisão do Classificador : 0.7835</p> <p>Sensibilidade : 0.5629</p> <p>Especificidade : 0.8216</p>
Validação	
	<p>Precisão do Classificador : 0.4838</p> <p>Sensibilidade : 0.5074</p> <p>Especificidade : 0.4265</p>
Teste	
	<p>Precisão do Classificador : 0.2707</p> <p>Sensibilidade : 0.4085</p> <p>Especificidade : 0.5366</p>

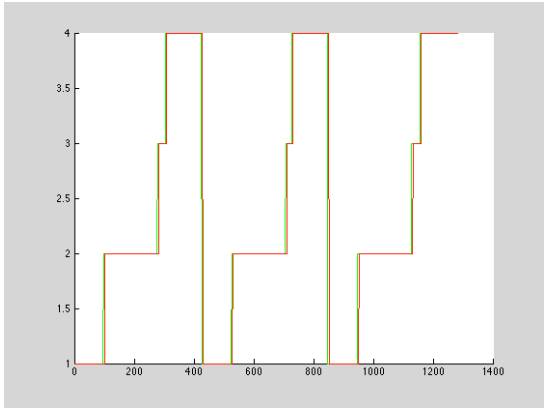
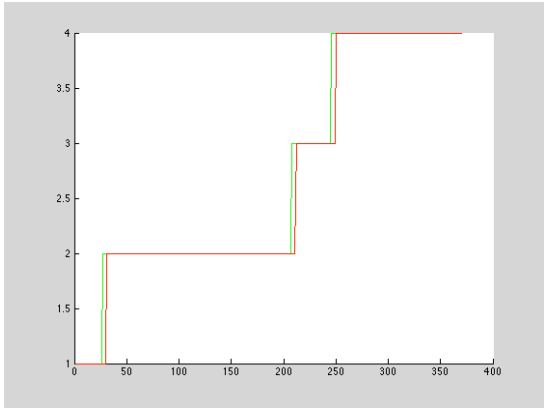
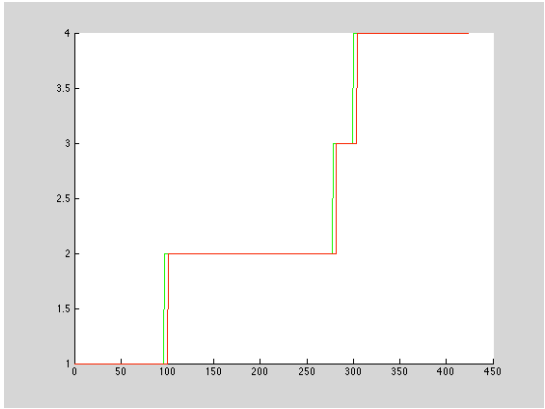
5 Fase 3 – Dados Intracranianos

Nesta fase do trabalho considerámos como input os dados obtidos directamente do cérebro, ou seja, os dados foram obtidos através de uma rede implantada directamente sobre o cérebro.

Os resultados obtidos foram tratados com a melhor rede neuronal obtida até ao momento, a Narxnet, capaz de retirar informação dinâmica de um sistema.

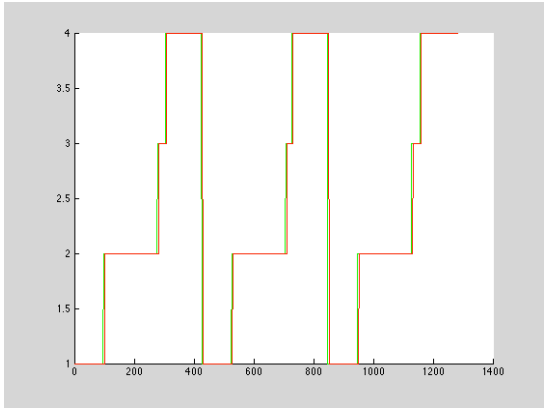
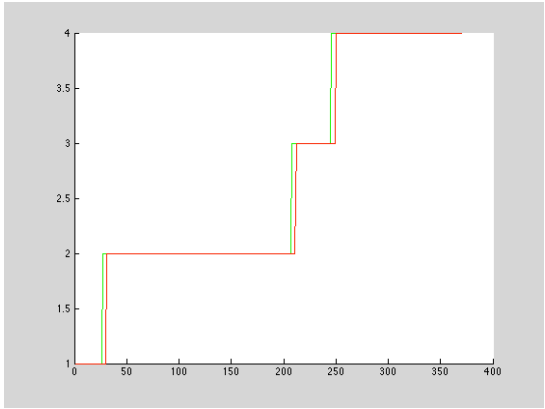
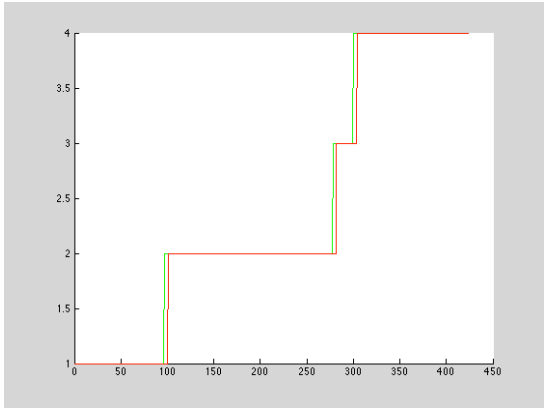
Rede NarxNet com dados intracranianos ficheiro rand

Camada escondida com 10 neurónios , função de treino 'traingdx', função de performance 'mse', erro médio quadrático, inputDelays 1:5 feedbackDelays 1:5.

Treino	
	Precisão do Classificador : 0.9655 Sensibilidade : 0.9779 Especificidade : 0.9836
Validação	
	Precisão do Classificador : 0.9671 Sensibilidade : 0.9779 Especificidade : 0.9783
Teste	
	Precisão do Classificador : 0.9714 Sensibilidade : 0.9779 Especificidade : 0.9832
Os resultados obtidos foram bons apesar de estarmos à espera que fossem bastante melhores que os resultados obtidos quando testámos a rede com dados recolhidos no coro cabludo.	

Rede NarxNet com dados intracranianos ficheiro prop

Camada escondida com 10 neurónios , função de treino 'traingdx', função de performance 'mse', erro médio quadrático, inputDelays 1:5 feedbackDelays 1:5.

Treino	
	Precisão do Classificador : 0.9655 Sensibilidade : 0.9779 Especificidade : 0.9836
Validação	
	Precisão do Classificador : 0.9671 Sensibilidade : 0.9779 Especificidade : 0.9783
Teste	
	Precisão do Classificador : 0.9714 Sensibilidade : 0.9779 Especificidade : 0.9832

6 Conclusão

Através da realização deste trabalho foi-nos possível testar diversas redes neuronais e obter conhecimento acerca das suas vantagens e desvantagens. Observámos que existem redes que não têm bom resultado para este tipo de problema, uma vez que, são redes que não têm em consideração resultados passados e, por isso, não apresentam bons resultados. Quando construídas redes que tomam isso em consideração foi notável a grande melhoria a nível de precisão do classificador bem como a melhorias a nível de especificidade e sensibilidade.

Quanto à escolha de um subset mais pequeno de características, de entre as 132 consideradas inicialmente, escolhemos as 6 melhores. Por outras palavras, foram escolhidas as 6 características que estão mais activas durante os estados pré-ictais. São elas: [5 27 49 71 93 115].

Com estas características os resultados foram semelhantes aos melhores obtidos com as 132 ao que se adicionam as melhorias de desempenho. Para além disto, num contexto real, isto quereria dizer que uma pessoa utilizaria apenas 6 sensores ao invés dos 132 para previsão de uma crise epiléptica. Isto revelar-se-ia bastante mais confortável para o doente.

A nível da comparação entre os resultados obtidos com os dados intracranianos foi possível verificar que, apesar das melhorias verificadas em termos de desempenho, não se justificaria uma intervenção cirúrgica para a colocação dos sensores no cérebro. Por isso, melhor sistema que poderíamos propor seria um sistema de 6 sensores a recolher informação pelo lado de fora do cérebro.